

GPT 模型组合与预算

更新：2026-09-25。公司已采购 OpenAI GPT，本文按效果从最好到最差列出可选的模型组合，并给出单任务成本与月预算，作为选型与报预算的依据。

当前云端默认：A 顶配组合（生成与评审都用 gpt-6-astra）。

1. 单价（OpenAI 官方 Standard 价，每百万 token，美元）

型号	代际 / 档位	输入	缓存输入	输出	温度限制
gpt-6-astra	GPT-6 旗舰	10.00	1.00	50.00	只能 1
gpt-6-sol	GPT-6 中档	2.00	0.20	10.00	只能 1
gpt-6-luna	GPT-6 低价	0.10	0.01	0.50	只能 1
gpt-5.6-sol	上一代旗舰	4.00	0.40	20.00	只能 1
gpt-5.6-terra	上一代中档	2.00	0.20	12.00	只能 1
gpt-5.6-luna	上一代低价	0.20	0.02	1.20	只能 1
gpt-5.5	前两代旗舰	5.00	0.50	30.00	只能 1
gpt-5.4	前两代主力	2.50	0.25	15.00	可 0.3
gpt-5.4-mini	轻量	0.75	0.075	4.50	可 0.3
gpt-5.4-nano	最轻	0.20	0.02	1.25	可 0.3
text-embedding-3-large	知识库向量化	0.13	—	—	—

*-pro 型号不支持 chat/completions 接口，平台无法使用，不列。

2. 一个任务用多少 token

按本地 4 个真实生成任务的 AI 调用日志取均值（每任务约 11 次模型调用）：

环节	输入 token	输出 token	说明
需求拆解（测试点）	9K	15K	1—2 次
用例生成	41K	69K	按模块并行，约 6 次
覆盖查漏、语义查重、驳回修改	9K	10K	视需求而定
用例评审	30K	16K	最多 3 轮，约 4 次
合计	约 75K	约 81K	典型任务

预算按「生成侧 45K 入 / 65K 出，评审侧 30K 入 / 16K 出」计算。本地日志里最大的一次任务是 123K 入 / 221K 出，作为「大任务」上限参考。

3. 组合表（效果从好到差）

效果排序依据 OpenAI 官方档位：GPT-6 > GPT-5.6 > GPT-5.5 > GPT-5.4；同代内 astra/sol > terra > luna。评审模型对最终质量的影响大于生成模型，所以 B 排在 C 之前。

排名	组合	生成模型	评审模型	单任务	大任务	适用
A	顶配（当前默认）	gpt-6-astra	gpt-6-astra	\$4.80	\$12.3	效果优先，不计成本
B	旗舰评审	gpt-6-sol	gpt-6-astra	\$1.84	\$4.6	质量接近顶配，成本降 6 成
C	均衡	gpt-6-sol	gpt-6-sol	\$0.96	\$2.5	日常主力
D	上一代旗舰	gpt-5.6-sol	gpt-5.6-sol	\$1.92	\$4.9	不推荐：比 B 贵且弱
E	5.5 双用	gpt-5.5	gpt-5.5	\$2.81	\$7.3	不推荐：比 B 贵且弱
F	稳定输出	gpt-5.4	gpt-5.4	\$1.40	\$3.6	唯一能用 0.3 温度的组合，输出最可复现
G	经济	gpt-6-sol	gpt-6-luna	\$0.75	\$1.9	评审降档，成本压到 C 的 8 成
H	最省	gpt-6-luna	gpt-6-luna	\$0.05	\$0.12	批量试跑、演示

D 和 E 被 B 完全压制（更贵且效果更差），只是因为型号还在清单里才列出，实际不要选。

4. 月预算

单任务成本 × 任务数 × 1.1（需求分析、依赖识别、对话修订、图片理解等零散调用按 10% 计入）。

组合	50 任务/月	200 任务/月	500 任务/月
A 顶配	\$264	\$1,056	\$2,640
B 旗舰评审	\$101	\$405	\$1,012
C 均衡	\$53	\$211	\$528
F 稳定输出	\$77	\$309	\$771
G 经济	\$41	\$165	\$413
H 最省	\$3	\$11	\$26

知识库向量化按每份文档 5 万字估算，约 \$0.005，可忽略。

顶配组合按 200 任务/月报预算约 \$1,100，留 30% 余量报 \$1,500/月。大需求（十几个模块、上百条用例）单任务可到 \$12 以上，若这类任务占比高，按 \$2,000/月 报。

5. 使用与切换

- 生成任务创建时可单独指定「评审模型」，不指定时评审与生成同模型。顶配组合即两者都不指定，默认 gpt-6-astra。
- 切换组合只需在「系统设置 → 模型配置」改默认模型，任务级选评审模型；不用重启。
- GPT-6、5.6、5.5 系温度只能填 1；只有 5.4 系能用 0.3。页面编辑这些条目时不要改温度，否则调用直接报 400 并落到降级链路。
- 降级链路：gpt-6-astra → gpt-6-sol → gpt-6-luna → gpt-5.4 → gpt-5.4-nano。OpenAI 单个型号故障时自动向下，不会中断任务。
- 实际用量在「AI 中心 → 调用日志」按用途、模型、任务统计，运行一个月后用真实数据回填本表的 token 画像。

6. 数据来源

- 单价：OpenAI 官方定价页 <https://developers.openai.com/api/docs/pricing>
- 型号定位：OpenAI Model guidance <https://developers.openai.com/api/docs/guides/latest-model>
- token 画像：本地库 ai_calls 表，2026-09 的 4 个生成任务